



โครงการ Project-Based Learning 1 (PBL1)

การจำแนกกลุ่ม 3 ชนิด และ การจำแนก กะเพรา และ ໂຮງພາ ด້ວຍ **Machine Learning**

รายวิชา **968-352 Machine Learning**

วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยสงขลานครินทร์ วิทยาเขตภูเก็ต

อาจารย์ประจำวิชา : ผศ.ดร. ชวัญกมล ดิษฐกัญจน์

ผู้รับผิดชอบโครงการ

นายรัฐภูมิ รอดนิล

รหัสนักศึกษา

6630611025

หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาการคอมพิวเตอร์

ภาคเรียนที่ 1 ปีการศึกษา **2568**

Table of Contents

บทที่ 1 บทนำ.....	3
1.1 ที่มาและความสำคัญของโครงการ	3
1.2 วัตถุประสงค์	3
1.3 ขอบเขตของงาน	3
 บทที่ 2 วิธีดำเนินการ.....	4
2.1 ข้อมูลและการเตรียมข้อมูล	4
2.2 Feature Extraction.....	6
2.3 การทำ Augmentation.....	9
2.4 การพัฒนาโมเดล Machine Learning สำหรับการจำแนกกล้วย การพัฒนาโมเดล Machine Learning สำหรับการจำแนกกล้วย	12
2.5 การใช้ CNN สำหรับการจำแนกใบกะเพรา-ໂຮງພາ	12
 บทที่ 3 ผลการทดลอง	20
3.1 ผลการจำแนกสายพันธุ์กล้วยด้วย Machine Learning	20
3.2 ผลการจำแนกใบกะเพราและໂຮງພາด้วยโมเดล CNN	22
3.3 ตัวอย่างภาพของข้อมูลที่ใช้ในการทดลอง	43
 บทที่ 4 อภิปรายผล	46
4.1 เปรียบเทียบโมเดลที่ดีที่สุดในแต่ละกรณี	46
4.2 นัยหา Overfitting ที่พบ	46
4.3 การวิเคราะห์จาก Confusion Matrix.....	46
4.4 ข้อตีอเลี่ยของวิธีการแต่ละแบบ	47
4.5 ข้อสร้างเกตเพิ่มเติม	47

บทที่ 1 บทนำ

1.1 ที่มาและความสำคัญของโครงการ

โครงการนี้เป็นส่วนหนึ่งของการเรียนรู้เชิงปฏิบัติ (Project-Based Learning) ในวิชา Introduction to Machine Learning ซึ่งมุ่งเน้นการประยุกต์ใช้ Machine Learning ในการแก้ปัญหาจริง

โดยโครงการนี้ตั้งเป้าที่จะทำการจำแนกประเภทของพืช 2 กลุ่ม ได้แก่ การจำแนกสายพันธุ์ของกล้วยจากภาพผล (3 สายพันธุ์คือ กล้วยหอม กล้วยน้ำว้า และกล้วยไข่) และ การจำแนกชนิดของใบกะเพราและใบโหระพา จากภาพถ่าย

ทั้งสองกรณีมีความสำคัญในทางการเกษตรและอุตสาหกรรมอาหาร

เนื่องจากการระบุสายพันธุ์กล้วยที่ถูกต้องจะช่วยในการคัดเลือกสายพันธุ์สำหรับการเพาะปลูกหรือการค้า

ส่วนการแยกกะเพรา กับโหระพา ซึ่งไม่มีลักษณะคล้ายกันจะช่วยลดความสับสนในการผลิตและจ้าหน่ายพืชสมุนไพรไทย การใช้ Machine Learning และ Deep Learning

ในการแก้ปัญหานี้จะช่วยเพิ่มความถูกต้องและรวดเร็วในการจำแนกเมื่อเทียบกับวิธีการดั้งเดิมที่ต้องอาศัยผู้เชี่ยวชาญ

1.2 วัตถุประสงค์

- 1) เพื่อศึกษาการพัฒนาโมเดล Machine Learning
- 2) เพื่อพัฒนาโมเดล Machine Learning สำหรับการจำแนกสายพันธุ์ของกล้วยสามสายพันธุ์จากภาพถ่ายของผลกล้วย โดยทดลองใช้เทคนิคการสกัดคุณลักษณะต่าง ๆ และวิธีการจำแนกอย่างน้อย 5 วิธี (เช่น Decision Tree, Random Forest, Naïve Bayes, Logistic Regression และ Neural Network)
- 3) เพื่อพัฒนาโมเดล Convolutional Neural Network (CNN) ด้วยวิธีการ transfer learning หรือ fine-tuning สำหรับการจำแนกชนิดของใบกะเพราและใบโหระพา และเปรียบเทียบประสิทธิภาพของสถาปัตยกรรม CNN อย่างน้อย 5 แบบ
- 4) เพื่อเปรียบเทียบประสิทธิภาพระหว่างวิธีการเรียนรู้ของเครื่องแบบดั้งเดิมที่ใช้การสกัดคุณลักษณะเชิงวิเคราะห์ (feature engineering) กับวิธีการเรียนรู้เชิงลึกที่ใช้การ transfer learning
ในด้านความแม่นยำในการจำแนกและปัญหาที่อาจเกิดขึ้น เช่น การฝึกโมเดลมากเกินไป (overfitting)
- 5) เพื่อสรุปข้อดีข้อเสียของแต่ละแนวทางและเสนอแนะแนวทางปรับปรุงสำหรับงานวิจัยหรือการประยุกต์ใช้ในอนาคต

1.3 ขอบเขตของงาน

งานนี้มุ่งเน้นที่การจำแนกภาพนิ่งของพืชในสองกรณีดังกล่าวโดยใช้ข้อมูลชุดเล็กที่จัดเตรียมไว้ ได้แก่ ชุดข้อมูลภาพผลกล้วย 3 สายพันธุ์ (ได้มาจากลิงก์ข้อมูลที่กำหนด) และชุดข้อมูลภาพใบกะเพราและใบโหระพาจำนวนรวม 200 ภาพ (อย่างละ 100 ภาพ จากการรวบรวมออนไลน์) การทดลองถูกจำกัดให้อยู่ในขอบเขตของการใช้โมเดลเรียนรู้ของเครื่องพื้นฐานและโมเดล CNN สถาปัตยกรรมที่เป็นที่รู้จัก ไม่ได้ครอบคลุมไปถึงการสร้างสถาปัตยกรรม CNN ขนาดใหญ่ขึ้นเองหรืองานประยุกต์อื่น ๆ นอกจากนี้ การประเมินประสิทธิภาพจะพิจารณาจากความแม่นยำ (Accuracy) และค่าการสูญเสีย (Loss) บนชุดข้อมูลทดสอบ/validation เป็นหลัก โดยไม่ลงลึกถึงการวัดเชิงลึกอื่น เช่น F1-score หรือ AUC เนื่องจากโจทย์มุ่งเน้นที่ Accuracy/Loss เป็นสำคัญ

บทที่ 2 วิธีดำเนินการ

2.1 ข้อมูลและการเตรียมข้อมูล

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=62,
    # stratify=y # พยายามให้สัดส่วนคลาสใกล้เคียงกัน
)
```

รูปภาพ 2.1.1 แสดงถึงการแบ่ง train-test split 80/20 ของ Part machine learning

ในการทดลองแรกใช้ชุดข้อมูลภาพถ่ายผลกลั่นสารสายพันธุ์ ได้แก่ กลั่นหอม กลั่นน้ำว้า และกลั่นไก่ ซึ่งได้มาจากการแหล่งข้อมูลที่กำหนด (ประมาณสายพันธุ์ละ 50 ภาพ) แต่ละภาพแสดงผลกลั่นจากหลังหากหอย

การเตรียมข้อมูลเบื้องต้นประกอบด้วยการปรับขนาดรูปภาพให้เหมาะสมและการแปลงภาพเป็นโโนนสีเทา (Augmentation) นอกจากนี้อาจมีการปรับแก้ความคมชัดหรือการตัดส่วนเกินของภาพตามความจำเป็น จากนั้นทำการแบ่งชุดข้อมูลออกเป็นสองส่วน ได้แก่ ชุดข้อมูลฝึก (training set) ประมาณ 80% และ ชุดข้อมูลทดสอบ (test set) ประมาณ 20% โดยเป็นการแบ่งแบบสุ่มโดยรักษาสัดส่วนของแต่ละสายพันธุ์ให้ใกล้เคียงกัน เพื่อใช้ประเมินโมเดลภายหลัง

```
train_ds = tf.keras.utils.image_dataset_from_directory(
    DATA_DIR,
    validation_split=0.20,
    subset="training",
    seed=SEED,
    image_size=IMG_SIZE,
    batch_size=BATCH_SIZE,
    label_mode='int'
)
val_ds = tf.keras.utils.image_dataset_from_directory(
    DATA_DIR,
    validation_split=0.20,
    subset="validation",
    seed=SEED,
    image_size=IMG_SIZE,
    batch_size=BATCH_SIZE,
    label_mode='int'
)
```

รูปภาพ 2.1.1 แสดงถึงการแบ่ง train-test split 80/20 ของ Part CNN

(ผลการรายงานจะเน้นที่ชุดทดสอบ (Validation) เท่านั้นตามโจทย์กำหนด)

สำหรับการทดลองที่สองใช้ ชุดข้อมูลภาพถ่ายใบหน้าและใบโทรศัพท์ในภาษาไทยและภาษาอังกฤษเน็ตและการถ่ายภาพจริงอย่างละ 100 ภาพ (รวม 200 ภาพ) โดยตัวอย่างภาพทั้งสองประเภทมีลักษณะคล้ายคลึงกัน (เป็นใบหน้าและใบโทรศัพท์ที่มีสีเขียวไกล์คึ่งกัน)
ข้อมูลถูกแบ่งเป็น ชุดเรียนรู้ 80% และ ชุด validation 20% ในทำนองเดียวกับกรณีแรก อย่างไรก็ตาม ในการใช้โมเดล CNN การแบ่งนี้ทำหน้าที่เสมือนชุดฝึกและชุดตรวจสอบ (validation)

```
def prepare(ds, training=False):
    ds = ds.cache()
    if training:
        ds = ds.shuffle(1000, seed=SEED)
    return ds.prefetch(AUTOTUNE)
```

เนื่องจากไม่มีชุดทดสอบแยกต่างหาก ทั้งนี้ได้ดำเนินการ shuffle ข้อมูลและ ไม่ข้าบคุกคลตันทาง (หากภาพหลายภาพมาจากแหล่งเดียวกันหรือถ่ายจากต้นเดียวกัน จะพยายามกระจายในฝึก/ทดสอบให้ต่างกัน)
เพื่อบังกันการเรอนเอียงของโมเดล

- **ds.cache()**
เก็บผลลัพธ์ของ dataset ไว้ในหน่วยความจำ (หรือดิสก์) หลังจากค่าอ่านครั้งแรก ทำให้รอบถัดไปไม่ต้องอ่านไฟล์จากดิสก์ซ้ำ ช่วยให้การฝึกโมเดลเร็วขึ้นอย่างมีนัยสำคัญ
- **ds.shuffle(1000, seed=SEED)** (ใช้เฉพาะตอน training)
ทำการสุ่มลำดับตัวอย่างอย่างต่อเนื่อง โดยใช้ buffer ขนาด 1000 ตัวอย่าง
ช่วยให้โมเดลไม่เห็นข้อมูลในลำดับเดิม ๆ, ลดการเกิด pattern ที่ทำให้การเรียนรู้ชำนาญ (bias), การใช้ seed ทำให้ผลการสุ่มสามารถทำซ้ำได้
- **ds.prefetch(AUTOTUNE)**
สั่งให้ TensorFlow เตรียม batch ตัดไปไว้ล่วงหน้าในขณะที่โมเดลกำลังฝึกกับ batch ปัจจุบัน
ช่วยลดเวลาว่างของ GPU/CPU, ทำให้การทำงานรวดเร็วขึ้น

2.2 Feature Extraction

สำหรับการจำแนกสายพันธุ์กล้วย งานนี้ใช้การ Feature Extraction จากภาพแบบ feature engineering ที่ประกอบด้วย Shape, LBP Texture, และ HOG รวมกันเป็นเวกเตอร์คุณลักษณะขนาด 1778 มิติ ดังนี้:

```
# threshold to get banana shape
_, thresh = cv2.threshold(gray, 0, 255, cv2.THRESH_OTSU)
contours, _ = cv2.findContours(thresh, cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)

if len(contours) == 0:
    # no contour
    shape_features = np.zeros(4, dtype=np.float32)
else:
    cnt = max(contours, key=cv2.contourArea)
    x, y, w, h = cv2.boundingRect(cnt)

    aspect_ratio = w / float(h + 1e-6)
    extent = cv2.contourArea(cnt) / float(w * h + 1e-6)
    hull = cv2.convexHull(cnt)
    solidity = cv2.contourArea(cnt) / (cv2.contourArea(hull) + 1e-6)

    # contour length = banana curvature hint
    perimeter = cv2.arcLength(cnt, True)

shape_features = np.array([aspect_ratio, extent, solidity, perimeter], dtype=np.float32)
```

รูป 2.2.1 แสดงโค้ดในส่วนของ Shape features Extraction

Shape Features (4 ค่า): ใช้ Otsu threshold → หา contour → คำนวณ aspect ratio, extent, solidity และ perimeter เพื่อบอกลักษณะรูปทรงและความโค้งของผลกล้วย

```
# Local Binary Pattern
P = 8      # number of circular neighbors
R = 1      # radius
lbp = local_binary_pattern(gray, P, R, method='uniform')

(lbp_hist, _) = np.histogram(lbp.ravel(),
                             bins=np.arange(0, P + 3),
                             range=(0, P + 2))

lbp_hist = lbp_hist.astype(np.float32)
lbp_hist /= (lbp_hist.sum() + 1e-6)    # normalize

texture_features = lbp_hist
```

รูป 2.2.2 แสดงโค้ดในส่วนของ texture features Extraction

LBP Texture: ใช้ Local Binary Pattern ($P=8$, $R=1$, uniform) และสร้างอิฐโดยการ normalized เพื่อขีบायลักษณะพื้นผิว

```
hog_features = hog(  
    gray,  
    orientations=9,  
    pixels_per_cell=(16, 16),  
    cells_per_block=(2, 2),  
    block_norm='L2-Hys',  
    visualize=False,  
    transform_sqrt=True  
).astype(np.float32)
```

ขั้น 2.2.3 แสดงค่าด้านในส่วนของ Hog features Extraction

HOG Features: ใช้ orientations=9, pixels_per_cell=(16,16), cells_per_block=(2,2), block_norm='L2-Hys' เพื่อจับลักษณะของแวรูปทรงโดยรวมของผลกล้าม

```

def load_dataset(dataset_dir):
    X = []
    y = []
    class_names = [] # เก็บชื่อคลาสตามลำดับ label

    # วนตามโฟลเดอร์ย่อย (แต่ละโฟลเดอร์ = 1 class)
    for label, class_folder in enumerate(os.listdir(dataset_dir)):
        class_path = os.path.join(dataset_dir, class_folder)
        if not os.path.isdir(class_path):
            continue

        class_names.append(class_folder)

        for filename in os.listdir(class_path):
            img_path = os.path.join(class_path, filename)

            # อ่านรูป
            img = cv2.imread(img_path)
            if img is None:
                continue # เพื่อไฟล์เปล่าๆ

            # สร้างฟีเจอร์
            feat = extract_features(img)

            X.append(feat)
            y.append(label)

    X = np.array(X, dtype=np.float32)
    y = np.array(y, dtype=np.int32)

    return X, y, class_names

```

รูป 2.2.4 แสดง function ที่ใช้เพื่อดึงรูปภาพ พร้อมกับสร้าง feature ไปในตัว

```

1 X, y, class_names = load_dataset(DATASET_DIR)
1
print("รูปทั้งหมด:", X.shape[0])
print("ขนาด feature ต่อรูป:", X.shape[1])
print("คลาสที่พบ:", class_names) # เช่น ['กล้วยไข่', 'กล้วยน้ำว้า', 'กล้วยหอม']

รูปทั้งหมด: 156
ขนาด feature ต่อรูป: 1778
คลาสที่พบ: ['egg', 'hom', 'numwa']

```

รูป 2.2.5 แสดงขนาดของ feature และ รูปทั้งหมด

ไฟล์นี้มีความกว้างเดอร์เดียวที่มีขนาด 1778 มิติ ใช้เป็นอินพุตของโมเดล Machine Learning สำหรับการจำแนกสายพันธุ์กล้วย

2.3 การทำ Augmentation

Machine Learning

```
def random_augment(img):
    """Apply a small random augmentation to img (BGR uint8)."""
    out = img.copy()
    h, w = out.shape[:2]

    ops = []

    # flip horizontally
    ops.append(lambda x: cv2.flip(x, 1))
    # rotate by small angle
    def rot(x):
        angle = random.uniform(-20, 20)
        M = cv2.getRotationMatrix2D((w/2, h/2), angle, 1.0)
        return cv2.warpAffine(x, M, (w, h), flags=cv2.INTER_LINEAR, borderMode=cv2.BORDER_REFLECT)
    ops.append(rot)

    # small translation
    def shift(x):
        tx = int(random.uniform(-0.05, 0.05) * w)
        ty = int(random.uniform(-0.05, 0.05) * h)
        M = np.float32([[1, 0, tx], [0, 1, ty]])
        return cv2.warpAffine(x, M, (w, h), borderMode=cv2.BORDER_REFLECT)
    ops.append(shift)

    # apply 1-2 random ops
    n_ops = random.choice([1, 2])
    chosen = random.sample(ops, n_ops)
    # print(chosen)
    for f in chosen:
        out = f(out)

    return out
```

รูปภาพ 2.3.1 แสดงถึงการทำฟังก์ชัน `random_augment`

ในงานนี้มีการออกแบบฟังก์ชัน `random_augment` เพื่อสร้างความหลากหลายให้กับข้อมูลภาพก่อนนำไปใช้ฝึกโมเดล Machine Learning โดยฟังก์ชันนี้จะสุ่มเลือก 1–2 เทคนิคการแปลงภาพจากชุดของการแปลง (**augmentation operations**) ที่เตรียมไว้ เพื่อเพิ่มความแข็งแกร่งให้โมเดลและลดโอกาสเกิด **overfitting** รายละเอียดของแต่ละการแปลงมีดังนี้

```
# flip horizontally
ops.append(lambda x: cv2.flip(x, 1))
# rotate by small angle
```

รูปภาพ 2.3.2 แสดงถึงการทำ horizontal Flip Augmentation

1. การกลับภาพในแนวอน (Horizontal Flip)

เทคนิคนี้ใช้คำสั่ง `cv2.flip(x, 1)` เพื่อกลับภาพจากซ้ายไปขวา โดยพิกัดของภาพจะถูกสลับในแนวนอน ทำให้วัตถุในภาพมีลักษณะเหมือนมองจากอีกด้านหนึ่ง

```

def rot(x):
    angle = random.uniform(-20, 20)
    M = cv2.getRotationMatrix2D((w/2, h/2), angle, 1.0)
    return cv2.warpAffine(x, M, (w, h), flags=cv2.INTER_LINEAR, borderMode=cv2.BORDER_REFLECT)
ops.append(rot)

```

รูปภาพ 2.3.3 แสดงถึงการทำ Random Small Rotation

2. การหมุนภาพด้วยมุมสุ่ม (Random Small Rotation)

ในฟังก์ชัน `rot(x)` มีการสุ่มมุมระหว่าง -20 ถึง +20 ของขา จากนั้นใช้ `cv2.getRotationMatrix2D` เพื่อสร้างเมทวิจาร์สำหรับหมุนภาพรอบจุดศูนย์กลางภาพ แล้วใช้ `cv2.warpAffine` เพื่อแปลงภาพตามเมทวิจาร์ดังกล่าว โดยใช้ `BORDER_REFLECT` เพื่อสะท้อนขอบของภาพแทนการสร้างขอบคำ

```

# small translation
def shift(x):
    tx = int(random.uniform(-0.05, 0.05) * w)
    ty = int(random.uniform(-0.05, 0.05) * h)
    M = np.float32([[1, 0, tx], [0, 1, ty]])
    return cv2.warpAffine(x, M, (w, h), borderMode=cv2.BORDER_REFLECT)
ops.append(shift)

```

รูปภาพ 2.3.4 แสดงถึงการทำ Random Translation

3. การเลื่อนภาพแบบสุ่ม (Random Translation)

ฟังก์ชัน `shift(x)` สุ่มระยะการเลื่อนในแนวอน (`tx`) และแนวตั้ง (`ty`) ประมาณ $\pm 5\%$ ของขนาดภาพ แล้วใช้เมทวิจาร์แปลงเชิงเส้น (affine transform)

$$\begin{bmatrix} 1 & 0 & tx \\ 0 & 1 & ty \end{bmatrix}$$

เพื่อนำมาบัญชาตำแหน่งของภาพโดยรวม ก่อนนำไปประมวลผลด้วย `cv2.warpAffine`

```

# apply 1-2 random ops
n_ops = random.choice([1, 2])
chosen = random.sample(ops, n_ops)
# print(chosen)
for f in chosen:
    out = f(out)

return out

```

รูปภาพ 2.3.5 แสดงถึงการทำงานของการสุ่มเลือก augment

หลังจากได้แล้ว ก็จะมีการสุ่มเลือกและเรียงลำดับการ Augment (Random Selection of Operations)

ฟังก์ชันจะสุ่มจำนวน augmentation ที่ต้องใช้ (1 หรือ 2) จากนั้นเลือกชุดของฟังก์ชันแปลงภาพแบบไม่ซ้ำกันด้วย `random.sample` และนำไปประยุกต์กับภาพตามลำดับที่สุ่มໄດ້

ตัวอย่างผลที่อาจเกิดขึ้น

- ใช้เพียงการหมุนอย่างเดียว
- ใช้การกลับภาพ + การเลื่อนภาพ
- ใช้การเลื่อนภาพ + การหมุนภาพ ฯลฯ

CNN

```

9 data_augment = keras.Sequential([
8     layers.RandomFlip("horizontal"),
7     layers.RandomRotation(0.10),
6     layers.RandomZoom(0.12),
5     layers.RandomContrast(0.10),
4     layers.RandomTranslation(0.08, 0.08),
3     layers.RandomBrightness(0.12),
2     layers.GaussianNoise(0.01),
1 ], name="augment")
2

```

ในส่วนนี้มีการสร้างレイเยอร์ **data_augment** แบบ Sequential ซึ่งทำหน้าที่แปลงภาพแบบสุ่มระหว่างการฝึกโมเดล โดยแต่ละレイเยอร์มีบทบาทดังนี้

1. RandomFlip("horizontal") – การกลับภาพในแนวนอน

ช่วยเพิ่มความหลากหลายของทิศทางวัตถุ
ทำให้โมเดลไม่ยึดติดกับด้านซ้าย/ขวาของภาพ

2. RandomRotation(0.15) – การหมุนภาพแบบสุ่ม

หมุนภาพภายในช่วงประมาณ $\pm 15\%$ ของวงรอบ (ประมาณ ± 27 องศา)
ทำให้โมเดลทนต่อมุมเอียงของวัตถุในภาพ

3. RandomZoom(0.15) – การซูมเข้า/ออกแบบสุ่ม

จำลองสถานการณ์ที่กล้องถ่ายภาพระยะใกล้หรือไกลแตกต่างกัน
ช่วยให้โมเดลเข้าใจว่าวัตถุเดียวกันอาจมีขนาดต่างกันในภาพ

4. RandomContrast(0.15) – การปรับค่า.contrast แบบสุ่ม

จำลองสภาพแสงที่แตกต่าง เช่น ภาพมืด ภาพสว่าง
ช่วยให้โมเดลแยกแยะวัตถุได้ดีขึ้นแม้สภาพแสงไม่สม่ำเสมอ

5. RandomTranslation(0.1, 0.1) – การเลื่อนตำแหน่งวัตถุแบบสุ่ม

เลื่อนภาพในแนวนอนและแนวตั้งประมาณ 10% ของขนาดภาพ
ลดการยึดติดว่าควรวัดถูกต้องอยู่กลางภาพเสมอ

2.4 การพัฒนาโมเดล Machine Learning สำหรับการจำแนกกลุ่ม ทาง การพัฒนาโมเดล Machine Learning สำหรับการจำแนกกลุ่ม

หลังจากได้เวคเตอร์คุณลักษณะของผลกลุ่มล่างแล้วจะต้องหาโมเดลจำแนก (**Classifier**) โดยทดลองอย่างน้อย 5 วิธีการ ดังต่อไปนี้:

- Decision Tree:** โครงสร้างของต้นไม้จะทำการแบ่งข้อมูลออกเป็นกลุ่มตามเงื่อนไขของคุณลักษณะ เช่น **shape**, **texture**, หรือ **hog feature** จะรวมทั้งในสุดท้ายจำแนกกลุ่มโดยใช้ค่าบวกทุกชนิดการผีกไม้เดลฟี่เกณฑ์ เช่น **Gini index** หรือ **entropy** เพื่อเลือกคุณลักษณะที่ดีที่สุดในการแยกข้อมูลที่แต่ละโนนด แม้ว่าโมเดล **Decision Tree** จะสามารถตีความผลการตัดสินใจได้ง่ายและเป็นมิตรกับการอธิบายผลลัพธ์
- Random Forest:** เป็นการรวมรุ่นของต้นไม้ตัดสินใจจำนวนหลายต้น ไมเดลสุมป่าจะสร้างต้นไม้ห้วย ๆ ต้นจากการสุมตัวอย่างข้อมูลและสุมเลือกชุดคุณลักษณะบางส่วนในการแบ่งแต่ละโนนด ผลการจำแนกสุดท้ายจะใช้การโนนต์ส่วนใหญ่จากต้นไม้ทั้งหมด **Random Forest** มีความสามารถในการลดความลำเอียงของต้นไม้เดียวและลดการ **overfitting** ทำให้ตัวความแม่นยำสูงกว่าต้นไม้ตัดสินใจเดียว ผลการทดลองใช้ **Random Forest** คาดว่าจะให้ประสิทธิภาพที่ดีในการจำแนกสายพันธุ์กลุ่มล่างเนื่องจากการตัดสินใจจากคุณลักษณะหลายตัว
- Naïve Bayes:** เราใช้ตัวจำแนก **Naïve Bayes** แบบ **Gaussian** สำหรับคุณลักษณะต่อเนื่อง โดยคำนวณความน่าจะเป็นของคุณลักษณะของภาพที่จะอยู่ในแต่ละประเภทกลุ่ม ไมเดลนี้เรียนรู้ได้รวดเร็วและต้องการข้อมูลในการฝึกน้อย ทั้งยังสามารถจัดการกับคุณลักษณะที่มีมิติสูงได้ดี อย่างไรก็ตาม ความแม่นยำอาจต่ำกว่าเมื่อ **feature** ไม่มีความ **independence** และ **feature** มีความสัมพันธ์กัน
- Logistic Regression:** **Logistic Regression** จะสร้างสมการเชิงเส้นของ **vector**, **feature** และ **weight** เพื่อประมาณความน่าจะเป็นที่ภาพจะเป็นกลุ่มเป้าหมายแต่ละชนิด จากนั้นเลือกประเภทที่มีความน่าจะเป็นสูงสุดเป็นผลลัพธ์ ไมเดลนี้สามารถตีความน้ำหนักของคุณลักษณะว่าอันไหนสำคัญต่อการทำนาย อย่างไรก็ตาม เนื่องจากความซับซ้อนของความสัมพันธ์เป็นเชิงเส้น ไมเดลอาจมีความยากลำบากในการจำแนกกลุ่มล่าง
- Neural Network:** เราใช้โครงข่ายประสาทเทียมชนิด **Multilayer Perceptron (MLP)** ซึ่งประกอบด้วย ชั้นต่อชั้น 2 ชั้น ที่มีจำนวนโนนดเท่ากับ 256 และ 128 ตามลำดับ ใช้ฟังก์ชันกรุ่นแบบ **tanh** และใช้ **solver** แบบ **L-BFGS** สำหรับการหา **gradient** ซึ่งหมายความว่าต้องคำนึงถึงความสัมพันธ์เชิงซับซ้อนระหว่างคุณลักษณะของภาพ (**feature vector**) กับประเภทของกลุ่มล่าง 3 ชนิดได้ดีมากจากนี้ยังมีการตั้งค่า **max_iter = 1000** เพื่อให้สามารถฝึกไมเดลได้นานพอสำหรับ **convergence** อย่างไรก็ตาม ไมเดลอาจเสียเวลาเรียนรู้โดยใช้ชุด **validation** เพื่อควบคุมการเรียนรู้ให้อยู่ในร่วงที่เหมาะสม

ผลลัพธ์ที่ได้จากโมเดลแต่ละตัวจะนำมาเปรียบเทียบกันในบทที่ 3

2.5 การใช้ CNN สำหรับการจำแนกใบหน้า

สำหรับปัญหาการจำแนกใบหน้าที่มีคุณลักษณะใกล้เคียงกัน งานนี้เลือกใช้วิธี **Deep Learning** โดยอาศัยโครงข่าย **Convolutional Neural Network (CNN)** ที่ผ่านการฝึกมาก่อนบนชุดข้อมูลขนาดใหญ่ (**pre-trained on ImageNet**) และนำมาปรับใช้กับข้อมูลของเจ้า (**transfer learning**).

```

def head_block(x, num_classes, dropout=0.3, l2_weight=1e-4, MIXED=False, units=128):
    # 1) สรุป feature จาก CNN backbone
    x = layers.GlobalAveragePooling2D()(x)

    # 2) ทำไฟ distribution ของ feature นั้นชึ้น (ข้อมูลทั้ง train/val)
    x = layers.BatchNormalization()(x)

    # 3) Dense ชั้น 1 ชั้น (พอดีแล้วสำหรับ data เล็ก) + L2
    x = layers.Dense(
        units,
        use_bias=False,
        kernel_regularizer=regularizers.l2(l2_weight),
        dtype='float32' if MIXED else None,
    )(x)

    x = layers.BatchNormalization()(x)
    x = layers.Activation('relu')(x)

    # 4) Dropout กัน overfit
    x = layers.Dropout(dropout)(x)

    # 5) ชั้น output
    logits = layers.Dense(
        num_classes,
        kernel_regularizer=regularizers.l2(l2_weight),
        dtype='float32' if MIXED else None,
    )(x)

    out = layers.Activation('softmax', dtype='float32' if MIXED else None)(logits)
    return out

```

รูปภาพ 2.5.1 แสดงถึงฟังก์ชัน ของ head block

สำหรับสถาปัตยกรรมส่วนใหญ่ (ยกเว้น Xception ซึ่งใช้ head block ที่เรียบง่ายกว่าเล็กน้อย) งานนี้ใช้ head block ไม่เดลร่วมกัน ผ่านฟังก์ชัน head_block โดยมีโครงสร้างดังนี้

1. ใช้ Global Average Pooling สรุปคุณลักษณะเชิงพื้นที่จาก convolutional backbone
2. ทำ Batch Normalization เพื่อลดการกระจายของค่า feature และช่วยให้การฝึกนิ่งชึ้น
3. ใช้ชั้น Dense ชั้น 1 ชั้น ขนาด 128 หน่วย พร้อมตัวปรับน้ำหนักแบบ L2 (weight decay) เพื่อเพิ่มความสามารถในการเรียนรู้ความสัมพันธ์ที่ไม่เชิงเส้น
4. ทำ Batch Normalization และใช้ฟังก์ชันกรวยตันแบบ ReLU
5. ใช้ Dropout 0.3 ช่วยลดโอกาสการเกิด overfitting
6. ปิดท้ายด้วยชั้น Dense ขนาด 2 หน่วย (แทนคลาส holy basil และ Thai basil) ตามด้วยฟังก์ชัน Softmax เพื่อให้ได้ความน่าจะเป็นของแต่ละคลาส

งานนี้เราได้สร้าง function สำหรับการ build model ไว้เพื่อให้ง่ายต่อการนำมาใช้ช้า

```

def build_model(base, model_name, model_label):
    base.trainable = False

    inputs = keras.Input(shape=IMG_SIZE + (3,))
    x = data_augment(inputs, training=True)
    x = keras.applications.__getattribute__(model_name).preprocess_input(x)
    x = base(x, training=False)

    outputs = head_block(
        x,
        num_classes=num_classes,
        dropout=0.3,
        l2_weight=1e-4,
        MIXED=MIXED,
        units=128,
    )

    return keras.Model(inputs, outputs, name=model_label)

```

รูปภาพ 2.5.2 แสดงถึงฟังก์ชันการสร้าง model

base.trainable = False

รูปภาพ 2.5.3 แสดงถึง Freeze base

- กำหนด `base.trainable = False` เพื่อ freeze พารามิเตอร์ของชั้น convolution ทั้งหมด ไม่ให้เรียนรู้ใหม่ในช่วงแรก

```

inputs = keras.Input(shape=IMG_SIZE + (3,))
x = data_augment(inputs, training=True)

```

รูปภาพ 2.5.4 แสดงถึงการตั้งค่าของการสร้าง Model

- สร้าง input tensor ที่มีขนาดอุปแบบ (height, width, 3)
- ใช้ `data_augment` (ซึ่งเป็น Sequential layer) ทำการหมุน กลับด้าน ซูม และเลื่อนตำแหน่งภาพแบบสุ่มในทุก batch

```

x = keras.applications.__getattribute__(model_name).preprocess_input(x)

```

รูปภาพ 2.5.5 แสดงถึงการปรับภาพของการสร้าง model

- ปรับค่าสีของภาพให้เป็น domain ที่เหมาะสม Model เช่น
 - การปรับช่วงค่าสีให้อยู่ในช่วงที่ไม่เดลเรียนรู้ไว้

- ช่วยให้พิจารณาที่ผ่าน convolution ถูกแปลผลได้ถูกต้อง

```
x = base(x, training=False)
```

รูปภาพ 2.5.6 แสดงถึงการตั้งค่าของการสร้าง mobilenetv2

- ให้ Model เป็น feature extractor เพื่อตึงคุณลักษณะเชิงลึก (high-level features) ของภาพ
- ระบุ training=False เพื่อปิด dropout และ batch normalization ที่พบในบางโมเดลฐาน

```
outputs = head_block(
    x,
    num_classes=num_classes,
    dropout=0.3,
    l2_weight=1e-4,
    MIXED=MIXED,
    units=128,
)
```

รูปภาพ 2.5.7 แสดงถึงการใช้งาน head_block

งานทดลองใช้สถาปัตยกรรม CNN มาตรฐานจำนวน 5 แบบ ได้แก่

```
def build_mobilenetv2():
    base = keras.applications.MobileNetV2(
        include_top=False,
        weights="imagenet",
        input_shape=IMG_SIZE + (3,))
    return build_model(base,"mobilenet_v2","mobilenetv2")
```

รูปภาพ 2.5.8 แสดงถึงการใช้งาน mobilenetv2

MobileNetV2 – โมเดลขนาดเล็กที่ออกแบบให้ประยุกต์พารามิเตอร์และคำนวณเร็ว หมายเหตุว่าบันทึกนี้เป็นโมเดลที่มีความซับซ้อนมากกว่า MobileNetV1 แต่ใช้ทรัพยากร่นแรงกว่า

```

def build_xception(input_shape=IMG_SIZE + (3,), num_classes=num_classes):
    base = keras.applications.Xception(
        include_top=False,
        weights="imagenet",
        input_shape=input_shape
    )

    return build_model(base, "xception", "xception")

```

รูปภาพ 2.5.9 แสดงถึงการใช้งาน Xception

Xception – โมเดลที่ขยายแนวคิดของ Inception โดยใช้ depthwise separable convolution ทั้งเครือข่าย ซึ่งยังให้เรียนรู้ลักษณะเชิงพื้นที่ได้ลึกขึ้นพร้อมจำนวน参数น้อยกว่าที่คุณได้

```

def build_efficientnetb0():
    base = keras.applications.EfficientNetB0(
        include_top=False,
        weights="imagenet",
        input_shape=IMG_SIZE + (3,))
    return build_model(base, "efficientnet", "efficientnetb0")

```

รูปภาพ 2.5.10 แสดงถึงการใช้งาน EfficientNetB0

EfficientNetB0 – โมเดลที่ใช้แนวคิด compound scaling ใน การปรับ “ความลึก–ความกว้าง–ขนาดภาพ” อย่างสมดุล ทำให้หัวรุ่นเล็กอย่าง B0 ยังให้ความแม่นยำสูงเมื่อเทียบกับขนาดโมเดล

```

def build_resnet50v2():
    base = keras.applications.ResNet50V2(
        include_top=False,
        weights="imagenet",
        input_shape=IMG_SIZE + (3,))
    return build_model(base, "resnet_v2", "resnet50v2")

```

รูปภาพ 2.5.11 แสดงถึงการใช้งาน ResNet50V2

ResNet50V2 – เครือข่ายแบบ Residual Network 50 ชั้น ที่มี skip connections ช่วยแก้ปัญหา gradient หายไป เมื่อโมเดลลึกมาก และเรียนรู้ลักษณะที่ซับซ้อนได้ดี

```
def build_nasnetmobile():
    base = keras.applications.NASNetMobile(
        include_top=False,
        weights="imagenet",
        input_shape=IMG_SIZE + (3,))
    return build_model(base, "nasnet", "nasnetmobile")
```

รูปภาพ 2.5.12 แสดงถึงการใช้งาน NASNetMobile

NASNetMobile – โมเดลขนาดเล็กที่ได้จากเทคนิค Neural Architecture Search ออกแบบให้เหมาะสมกับงานบันคุณภาพที่ทรัพยากรำจាកด แต่ยังคงประสิทธิภาพที่ดี

ขั้นตอนการฝึกแบ่งเป็นสองช่วงหลัก

ช่วงที่ 1 – Frozen backbone

```
model = build_fn()
compile_model(model, lr=3e-4)

ckpt = keras.callbacks.ModelCheckpoint(
    filepath='best.keras',
    monitor='val_loss',
    save_best_only=True
)
history = model.fit(
    train_ds_aug,
    validation_data=val_ds_prep,
    epochs=EPOCHS,
    callbacks=[ckpt],
    verbose=2
)
```

รูปภาพ 2.5.13 แสดงถึง ช่วงที่ 1 ของ function train_and_eval

ในช่วงแรกของการฝึกโมเดล ได้ใช้เทคนิค Transfer Learning โดยกำหนดให้ ส่วนของ backbone ที่เป็น convolutional layers Freeze เพื่อป้องกันไม่ให้มีการอัปเดต Weight ของชั้นฐานที่ได้มาจาก ImageNet และฝึกเฉพาะส่วนหัว (classification head) ที่สร้างขึ้นใหม่เท่านั้น ซึ่งช่วยลดความเสี่ยงของ overfitting เมื่อจำนวนข้อมูลมีจำกัด

```
def compile_model(model, lr=1e-3):
    opt = keras.optimizers.Adam(learning_rate=lr)
    model.compile(optimizer=opt, loss='sparse_categorical_crossentropy', metrics=['accuracy'])
```

```
model = build_fn()
compile_model(model, lr=3e-4)
```

รูปภาพ 2.5.14 แสดงถึงโค้ดที่เริ่มต้นการ train model

- Optimizer: ใช้ตัวปรับพารามิเตอร์แบบ Adam
- Learning rate: เริ่มต้นที่ 3×10^{-4} (3e-4)
- Loss function: ใช้ sparse_categorical_crossentropy ซึ่งหมายความว่า label เป็น integer
- Metric: ใช้ค่า accuracy เป็นตัวชี้วัดหลัก

```
ckpt = keras.callbacks.ModelCheckpoint(
    filepath='best.keras',
    monitor='val_loss',
    save_best_only=True
)
```

รูปภาพ 2.5.15 แสดงถึงโค้ดตั้งค่า callback ของการ train

- บันทึกเฉพาะโมเดลที่ให้ค่า val_loss ต่ำที่สุด
- บันทึกการสูญเสียโมเดลที่ดีที่สุดในแต่ละ epoch ติดไปให้ผลลัพธ์ย่อลง
- ไฟล์ best.keras เป็นจุดตรวจ (checkpoint)

```
history = model.fit(
    train_ds_aug,
    validation_data=val_ds_prep,
    epochs=EPOCHS,
    callbacks=[ckpt],
    verbose=2
)
```

รูปภาพ 2.5.16 แสดงถึงโค้ดที่เริ่มต้น train model

- ฝึกทั้งหมด 100 epochs (ตามค่าที่ตั้งในตัวแปร EPOCHS)
- ใช้ชุด training augmented และ validation ที่ผ่านการเตรียมข้อมูลแล้ว
- บันทึกค่า loss และ accuracy ของทั้ง training และ validation ลงในตัวแปร history

ขั้นที่ 2 – ปรับจูนแบบละเอียด (Fine-tuning)

```

if hasattr(model.layers[2], 'trainable') and hasattr(model.layers[2], 'layers'):
    # Unfreeze last ~20% of layers (heuristic)
    base = None
    for lyr in model.layers:
        if isinstance(lyr, keras.Model) and lyr.name not in ['sequential', 'model']:
            base = lyr
    if base is None:
        # try find include_top=False backbone by type
        for lyr in model.layers:
            if isinstance(lyr, keras.layers.Layer) and hasattr(lyr, 'trainable') and len(lyr.weights) > 0:
                base = lyr

    if base is not None:
        total = len(base.layers) if hasattr(base, 'layers') else 0
        unfreeze_from = int(total * 0.8)
        if hasattr(base, 'layers') and total > 0:
            for i, lyr in enumerate(base.layers):
                lyr.trainable = (i >= unfreeze_from)

    compile_model(model, lr=1e-5)
    print(f"\nFine-tuning {model.name} from layer {unfreeze_from}/{total}")
    ft_history = model.fit(
        train_ds_aug,
        validation_data=val_ds_prep,
        epochs=max(8, EPOCHS//2),
        class_weight=class_weight,
        callbacks=[
            keras.callbacks.EarlyStopping(monitor='val_accuracy', patience=4, restore_best_weights=True)
        ],
        verbose=2
    )
}

```

รูปภาพ 2.5.17 แสดงถึงโค้ดในส่วนของการ fine-tuning

หลังจากฝึกโมเดลด้วย **backbone** แบบ **freeze** เรียบร้อยแล้ว ในขั้นที่สองมีการปรับจูนโมเดลเพิ่มเติมโดยเปิดให้บางส่วนของโมเดลฐาน (**backbone**) สามารถเรียนรู้จากข้อมูลชุดใหม่ได้ เทคนิคนี้เรียกว่า **Fine-tuning** ซึ่งช่วยให้โมเดลสามารถปรับตัวกับลักษณะเฉพาะของข้อมูลปัญญาจาริจได้ดียิ่งขึ้น โดยยังคงรักษาคุณลักษณะที่เรียนรู้จาก ImageNet ไว้เป็นฐาน โดยเปิดให้บางส่วนของ **backbone** สามารถเรียนรู้เพิ่มเติมจากข้อมูลใหม่ได้ ได้จะค้นหาโมเดลฐาน (**backbone**) จากชั้นภาษาในโมเดลหลัก และทำการ **unfreeze** ประมาณ **20%** ของชั้นสุดท้าย

```

total = len(base.layers) if hasattr(base, 'layers') else 0
unfreeze_from = int(total * 0.8)
if hasattr(base, 'layers') and total > 0:
    for i, lyr in enumerate(base.layers):
        lyr.trainable = (i >= unfreeze_from)

```

รูปภาพ 2.5.18 แสดงถึงโค้ดในส่วนของการ unfreeze

การเลือกเปิดเฉพาะชั้นบนสุดของ **backbone** มีจุดประสงค์เพื่อให้โมเดลสามารถปรับพื้นฐานระดับสูงให้เข้ากับลักษณะเฉพาะของข้อมูลจำแนกในโทรศัพท์ เพื่อให้มีร่วงกรุนโครงสร้างการเรียนรู้พื้นฐานซึ่งได้มาจาก ImageNet

หลังจาก **unfreeze** แล้ว โมเดลจะถูก **compile** ใหม่ด้วยอัตราการเรียนรู้ที่ต่ำมาก คือ

```
def compile_model(model, lr=1e-3):
    opt = keras.optimizers.Adam(learning_rate=lr)
    model.compile(optimizer=opt, loss='sparse_categorical_crossentropy', metrics=[ 'accuracy'])
```

compile_model(model, lr=1e-5)

รูปภาพ 2.5.18 แสดงถึงโค้ดในส่วนของการ compile model

ค่า learning rate ขนาดเล็กระดับ 1×10^{-5} ช่วยป้องกันไม่ให้การอัปเดตน้ำหนักทำลายข้อมูลไฟล์เจอร์ที่ backbone เคยเรียนรู้ไว้ ทำให้การปรับจูนเกิดขึ้นอย่างค่อยเป็นค่อยไปและมีความเสถียร

```
ft_history = model.fit(
    train_ds_aug,
    validation_data=val_ds_prep,
    epochs=max(8, EPOCHS//2),
    class_weight=class_weight,
    callbacks=[
        keras.callbacks.EarlyStopping(monitor='val_accuracy', patience=4, restore_best_weights=True)
    ],
    verbose=2
)
```

รูปภาพ 2.5.19 แสดงถึงโค้ดในส่วนของการ Train mode ของช่วง fine-tune

- การฝึกในช่วง Fine-tuning ถูกกำหนดให้ใช้จำนวน epoch อย่างน้อย **8 epochs** หรือ ครึ่งหนึ่งของจำนวน epoch เมื่อม (แล้วแต่จำนวนที่มากกว่า)
- เพื่อควบคุมไม่ให้มีเดลเกิดการ overfitting มากเกินไป มีการใช้ **EarlyStopping** โดยผ้าดูดค่า **val_accuracy** หากไม่ดีขึ้นภายใน 4 epoch ติดต่อกัน การฝึกจะหยุดลงและโหลดน้ำหนักที่ดีที่สุดกลับมาอีกครั้ง

บทที่ 3 ผลการทดลอง


3.1 ผลการจำแนกสายพันธุ์ลักษณะด้วย Machine Learning

ไมเดลทั้ง 5 รูปแบบที่พัฒนาในงาน (Decision Tree, Random Forest, Naïve Bayes, Logistic Regression และ MLP) ได้รับการประเมินบนชุดข้อมูลทดสอบของภาพกลักษณะสายพันธุ์ซึ่งในที่นี้ผลการวัดประสิทธิภาพหลักคือ ความแม่นยำ (Accuracy) ที่คำนวณจากเบอร์เร็นต์ของจำนวนภาพที่จำแนกสายพันธุ์ถูกต้องจากทั้งหมด

ตารางที่ 3.1 ผลการจำแนกสายพันธุ์กล้วยด้วยฟีเจอร์ 1778 มิติ (ค่าเฉลี่ยจาก Stratified K-Fold, k=5)

วิธีการ	ความแม่นยำบน validation (%)	ความแม่นยำฝึก (%)	train_loss_mean	val_loss_mean
Decision Tree	$87.39\% \pm 2.49$	100.00%	2.22e-16	4.5452
Random Forest	$97.65\% \pm 0.81$	100.00%	0.0860	0.2116
Naïve Bayes	$93.80\% \pm 2.29$	97.33%	0.9037	2.0270
Logistic Regression	$99.14\% \pm 0.80$	100.00%	0.1033	0.1246
Neural Network (MLP)	$96.59\% \pm 2.17$	99.84%	0.0090	0.3444

จากตารางที่ 3.1 จะเห็นว่าโมเดลที่ให้ความแม่นยำสูงที่สุดคือ Logistic Regression ($99.14\% \pm 0.80$) รองลงมาคือ Random Forest ($97.65\% \pm 0.81$) และ Neural Network (MLP) ($96.59\% \pm 2.17$) ซึ่งสะท้อนว่าโมเดลทั้งสามสามารถจัดการกับฟีเจอร์จำนวนมาก (1778 มิติ) ได้อย่างมีประสิทธิภาพ โดยเฉพาะ Logistic Regression ที่ทำผลงานได้ดีที่สุดแม้เป็นโมเดลเชิงเส้น เนื่องจากฟีเจอร์ที่สกัดมีความจำเพาะและแยกสายพันธุ์ได้อยู่แล้ว ส่วน Naïve Bayes ($93.80\% \pm 2.29$) แม้ให้ผลดีในระดับหนึ่งแต่ยังต้องว่าเพาะะข้อจำกัดด้านสมมติฐานความเป็นอิสระของฟีเจอร์ ขณะที่ Decision Tree มีความแม่นยำต่ำสุด ($87.39\% \pm 2.49$) และแสดงอาการ overfitting อย่างชัดเจน โดย train accuracy สูงถึง 100% แต่ validation accuracy ต่ำกว่ามาก ซึ่งแสดงคลื่องกับลักษณะของโมเดลตันไม่ทั่วทั้งจำชื่อมูลฝิกมากเกินไปหากไม่ได้ควบคุมความลึกอย่างเพียงพอ



ผลจาก Confusion Matrix (กล้วย 3 สายพันธุ์ – จากการทดลองจริง)

โมเดลทั้งหมดให้ผลสอดคล้องกับค่าความแม่นยำ โดยมีจุดเด่นดังนี้:

Decision Tree มักสับสน กลัวยอมมากที่สุด ซึ่งตรงกับการเกิด overfitting

Random Forest ให้การจำแนกที่นิ่งกว่า ลดข้อผิดพลาดในคุณภาพเดียวกัน

Naïve Bayes มีแนวโน้มทำนายผิดในคลาสที่มี distribution ทับซ้อนสูง เช่น ลักษณะพื้นผิวใกล้กัน

Logistic Regression จำแนกห้องสมัยพัฒนาได้เกือบสมบูรณ์โดยเฉพาะ กลัวยอมที่เด่นชัดที่สุด

MLP ให้ผลดีมากแต่ยังมีจุดที่สับสนเล็กน้อยในกลัวยอมน้ำร้ากับกลัวไฟ

โดยรวม Confusion Matrix ชี้ว่า คุณที่สับสนมากที่สุดคือ น้ำร้า-ยอม ขณะที่ กลัวยอม ถูกจำแนกถูกต้องสูงที่สุดในทุกโมเดล

3.2 ผลการจำแนกใบกะเพราและโภระพาด้วยโมเดล CNN

ในการทดลองส่วนที่สอง เราได้ฝึกโมเดลโครงสร้าง CNN ที่มีสถาปัตยกรรมแตกต่างกัน 5 แบบโดยใช้วิธี transfer learning ผลลัพธ์ค่าความแม่นยำ (Accuracy) และความสูญเสีย (Loss) บนชุด validation ของแต่ละโมเดลสรุปแสดงในตารางที่ 3.2

ตารางที่ 3.2 ประสิทธิภาพของโมเดล CNN แต่ละสถาปัตยกรรมในการจำแนกใบกะเพรา-โภระพา (ชุดข้อมูล validation)

โมเดล CNN	ความแม่นยำ (%)	Loss (ค่าความสูญเสีย)
MobileNetV2	92.50	0.3125
EfficientNetB0	95.00	0.1499
NASNetMobile	92.50	0.2868
ResNet50V2	92.50	0.3098
Xception	90.00	0.2417

ผล Fine-tuning ของโมเดลแต่ละตัว

โมเดล CNN	val_accuracy	val_loss
MobileNetV2	0.8250	0.5801
EfficientNetB0	1.0000	0.0988
NASNetMobile	0.8750	0.3099
ResNet50V2	0.9250	0.3811
Xception	0.9000	0.2313

สรุปผลจากการ Fine-tuning

จากผล Fine-tuning จะเห็นว่าเมื่อเพียง EfficientNetB0 ที่ประดิษฐิภาพดีขึ้นอย่างชัดเจน ความแม่นยำเพิ่มจาก 95% เป็น 100% และ loss ลดลงเหลือเพียง ~0.0988 แสดงว่าโมเดลตอบสนองต่อการปรับพารามิเตอร์ระดับลึกได้ดี แม้ข้อมูลจะมีจำนวนจำกัด

โมเดลอื่น ๆ ไม่ได้มีแนวโน้มดีขึ้น โดยเฉพาะ MobileNetV2 และ NASNetMobile ที่ความแม่นยำลดลงและ loss สูงขึ้นหลัง fine-tune ซึ่งเป็นสัญญาณ overfitting จากข้อมูลที่มีจำนวนค่อนข้างน้อย ขณะที่ ResNet50V2 และ Xception แม้ความแม่นยำจะไม่ลดลงมาก แต่ไม่ได้ดีขึ้นเท่านั้น

ตารางเปรียบเทียบ Frozen vs Fine-tuned (ภาพรวม)

โมเดล CNN	Frozen Accuracy	Frozen Loss	Fine-tuned Accuracy	Fine-tuned Loss	แนวโน้ม
MobileNetV2	0.9250	0.3125	0.8250	0.5801	แย่ลง (overfitting)
EfficientNetB0	0.9500	0.1499	1.0000	0.0988	ดีขึ้นขัดเจน
NASNetMobile	0.9250	0.2868	0.8750	0.3099	แย่ลง
ResNet50V2	0.9250	0.3098	0.9250	0.3811	ไม่ดีขึ้น (loss แย่ลง)
Xception	0.9000	0.2417	0.9000	0.2313	เพิ่มเดิม (loss ดีขึ้น เล็กน้อย)

สรุปเทียบผลรวม

EfficientNetB0 เป็นโมเดลเดียวที่ fine-tuning แล้วดีขึ้นจริง

MobileNetV2 และ NASNetMobile แย่ลง อย่างเห็นได้ชัด เนื่องจาก overfitting

Xception และ ResNet50V2 แทบไม่เปลี่ยนแปลง และไม่สามารถเพิ่ม accuracy ได้จากข้อมูลชุดนี้


โดยภาพรวม แสดงให้เห็นว่าการ fine-tuning จะได้ผลก็ต่อเมื่อมोเดลมีความสมดุลระหว่างขนาดโมเดล—จำนวนพารามิเตอร์—และจำนวนข้อมูลที่มีเพียงพอ เช่น EfficientNetB0 สำหรับโมเดลที่ขับข้อนกันไปในบริบทของข้อมูลขนาดเล็กจะมีแนวโน้ม overfit เมื่อทำ fine-tuning | 0.8750 | 0.3099 |

โมเดล MobileNetV2, NASNetMobile และ ResNet50V2 ให้ผลใกล้เคียงกัน โดยมีความแม่นยำสูงถึง 92.50% แต่ค่า Loss ต่างกันเล็กน้อย ซึ่งบ่งชี้ว่าแต่ละสถาปัตยกรรมมีลักษณะการเรียนรู้ที่ต่างกัน โดย NASNetMobile มีค่า val_loss ต่ำที่สุดในกลุ่มของลงมา แสดงถึงการทำงานที่ค่อนข้างมั่นคง ขณะที่ ResNet50V2 และ MobileNetV2 ให้ความแม่นยำเท่ากันแต่ Loss สูงกว่าเล็กน้อย สำหรับโมเดล Xception แม้จะสถาปัตยกรรมที่ขับข้อนกันว่าบางโมเดล แต่ให้ความแม่นยำต่ำที่สุดในชุดนี้ที่ 90.00% ซึ่งอาจเกิดจากจำนวนข้อมูลที่มีจำกัด ทำให้โมเดลใหญ่ไม่สามารถเรียนรู้ได้เต็มที่และมีแนวโน้มเกิด overfitting ง่ายกว่า


โดยรวมแล้ว ผลลัพธ์ที่ได้เห็นว่า โมเดลขนาดเล็กถึงกลางที่มีประสิทธิภาพสูงและผ่านการออกแบบอย่างสมดุล เช่น EfficientNetB0 สามารถทำงานได้ดีกว่าโมเดลที่มีความขับข้อนสูงกว่าในชุดข้อมูลขนาดเล็ก นอกจากนี้ ค่าความสูญเสียที่ลดลงตามความแม่นยำที่สูงขึ้นบ่งบอกว่า โมเดลไม่ได้เพียงทำงานถูกต้องเท่านั้น แต่ยังทำงานด้วยความมั่นใจมากกว่าอีกด้วย

ในการวิเคราะห์เชิงลึกเพิ่มเติม เราได้พิจารณาพฤติกรรมการเรียนรู้ของโมเดล MobileNetV2 ซึ่งเป็นหนึ่งในโมเดลที่ทดลองโดยเปรียบเทียบระหว่างกรณี ฝึกเฉพาะชั้บนบนสุด (FROZEN BASE) กับกรณี ปรับค่าพารามิเตอร์แบบ fine-tuning รูปที่ 3.1 แสดงกราฟการเรียนรู้ของ MobileNetV2 เมื่อฝึกด้วย FROZEN BASE (Frozen) 。

เปรียบเทียบความสูญเสียและความแม่นยำระหว่างชุดฝึกและชุด validation ตลอด 100 epochs ในขณะที่รูปที่ 3.2 แสดงกราฟในกรณีที่ทำ fine-tuning โมเดล (ซึ่งฝึกต่อเนื่องเพียงไม่กี่ epochs ในที่นี้)



รูปที่ 3.1 กราฟแสดงค่าความสูญเสีย (loss) และความแม่นยำ (accuracy) ของการฝึกโมเดล MobileNetV2 โดยแซฟเฟิร์นโมเดล ไม่ปรับน้ำหนักของ convolutional layers จาก ImageNet (แกน x คือ epoch ตั้งแต่ 0 ถึง 100) จะเห็นว่าความสูญเสียชุดฝึก (train_loss – เส้นสีน้ำเงิน) ลดลงอย่างรวดเร็วในช่วงแรกและทรงตัวที่ค่าต่ำ (~0.2 หรือต่ำกว่า) ขณะที่ความสูญเสียชุด validation (val_loss – เส้นสีส้ม) ลดลงช้ากว่าและแกว่งอยู่ระหว่าง 0.3–0.5 ในช่วงกลางก่อนจะขึ้นเล็กน้อยในช่วงท้าย ส่วนกราฟความแม่นยำแสดงให้เห็นว่าโมเดลมีความแม่นยำชุดฝึก (train_acc) เพิ่มขึ้นถึงประมาณ 1.0 (100%) อย่างรวดเร็วและแกว่งอยู่ใกล้ค่านั้น ในขณะที่ความแม่นยำชุด validation (val_acc – เส้นสีส้มกราฟขวา) เริ่มต้นที่ประมาณ 0.5 และไต่ขึ้นมาที่ ~0.85–0.90 ภายใน ~10 epochs แต่อาจตกลงบ้างเล็กน้อยและแกว่งอยู่ในช่วง ~0.80–0.90 ตลอดการฝึก




รูปที่ 3.2 กราฟแสดงค่าความสูญเสียและความแม่นยำของโมเดล MobileNetV2 กรณีทำ Fine-tuning (ปรับค่า weight ในบางชั้นของ convolutional base) ที่ดำเนินการฝึกต่ออีก 5 epochs หลังจากฐานแซฟเฟิร์น โมเดลมีความแม่นยำชุดฝึกสูงขึ้นเล็กน้อย (~0.95 หรือ 95%) แต่ความแม่นยำชุด validation (เส้นสีส้ม) กลับลดต่ำลงจาก ~0.82 ในตอนเริ่มเหลือ ~0.78 เมื่อสิ้นสุด 5 epochs และค่าความสูญเสียบน validation เพิ่มขึ้น (จาก ~0.6 เป็น ~0.75) สะท้อนเป็นปัญหา Overfitting ที่เกิดขึ้นเมื่อทำการ fine-tune โมเดลด้วยข้อมูลจำนวนน้อยเกินไป

จากการรูปที่ 3.1 และ 3.2 จะเห็นแนวโน้มว่าเมื่อใช้ฐานโมเดลที่ฝึกจาก ImageNet โดยไม่ปรับน้ำหนัก (รูปที่ 3.1) โมเดลสามารถเรียนรู้ชั้นบนสุดให้เข้ากับปัญหาใหม่ได้ดีพอสมควร ความแม่นยำบน validation สูงถึง ~85–90% และ loss อยู่ระดับต่ำ โดยโมเดลไม่ได้แสดงอาการ overfit ชัดเจนมากนัก (val_acc และ train_acc ใกล้เคียงกันช่วงท้าย ๆ) ในทางกลับกัน เมื่ออนุญาตให้ปรับน้ำหนักระหว่างการ fine-tuning (รูปที่ 3.2) เราพบว่าความแม่นยำบนชุดฝึกเพิ่มสูงขึ้นอย่างรวดเร็วเกือบแตะ 95–100% ในไม่กี่ epoch แต่ความแม่นยำบน validation กลับลดต่ำลงและค่าความสูญเสียสูงขึ้น


แสดงว่าโมเดลเริ่มจดจำรายละเอียดของชุดฝึกมากเกินไปจนสูญเสียความสามารถในการทั่วไปกับข้อมูลใหม่ – ซึ่งเป็นลักษณะของการฝึกมากเกินไป (Overfitting) นั้นเอง

เพื่อทำความเข้าใจเชิงคุณภาพเกี่ยวกับข้อผิดพลาดของโมเดล เราได้สร้าง Confusion Matrix สำหรับโมเดล MobileNetV2 ทั้งในกรณีฐานะแข็งและกรณี fine-tuned ดังแสดงในรูปที่ 3.3 โดยแกนแนวตั้งคือประเภทจริงของภาพ (True label) และแกนแนวโน้มคือประเภทที่โมเดลทำนาย (Predicted label) ภายใต้ตารางมีตัวเลขจำนวนภาพในแต่ละกรณี (โมเดลทำนายเป็น X ในขณะที่จริง ๆ เป็น Y)




รูปที่ 3.3 confusion Matrix ของโมเดล MobileNetV2 บนชุดข้อมูล validation เปรียบเทียบระหว่าง (ซ้าย) FROZEN BASE และ (ขวา) Fine-tuned จะเห็นว่าในทั้งสองกรณี โมเดลสามารถจำแนกภาพใน holy_basil (กะเพรา) ได้ถูกต้องทั้งหมด (ทำนายเป็น holy_basil ถูกต้อง 22 ภาพ จากทั้งหมด 22 ภาพ ไม่มีข้อผิดพลาด) ในขณะที่การจำแนกใน Thai_basil (โหระพา) มีความสับสนเกิดขึ้น โดยกรณีฐานะแข็ง (รูปซ้าย) จำแนกไปโหระพาถูกต้อง 12 ภาพ และผิดเป็นกะเพรา 6 ภาพ ในขณะที่กรณี fine-tuned (รูปขวา) จำแนกโหระพาถูกต้อง 11 ภาพ และผิดเป็นกะเพรา 7 ภาพ จะเห็นว่าโมเดลที่ fine-tune แล้วไม่ได้ช่วยเพิ่มความแม่นยำสำหรับคลาสโหระพา แต่มี Hind-sampling ทำให้จำนวนผิดเพิ่มขึ้นเล็กน้อย (จาก 6 เป็น 7 ภาพ)

ต่อจากภาระโมเดล MobileNetV2 เราได้พิจารณา โมเดล Xception ซึ่งเป็นสถาปัตยกรรมที่ลึกกว่าและใช้ depthwise separable convolution เช่นเดียวกัน แต่มีโครงสร้างบล็อกที่ซับซ้อนกว่า รูปที่ 3.4 และ 3.5 แสดงกราฟการเรียนรู้ของ Xception ในกรณี Frozen base โดยรูปที่ 3.4 เป็นกราฟ loss (train_loss และ val_loss) และรูปที่ 3.5 เป็นกราฟ accuracy (train_acc และ val_acc) ตลอด 100 epochs




ข้อปฏิที่ 3.4 กราฟ loss ของโมเดล Xception (Frozen base) – เผี้ยน train_loss (สีฟ้าเงิน) และ val_loss (สีส้ม) ลดลงต่อเนื่องตั้งแต่ต้นจนจบการฝึก โดย val_loss จะค่อนข้างลดลงอย่างรวดเร็วจากрова 0.7 ลงมาใกล้ 0.25 ในช่วงท้าย และมักอยู่ต่ำกว่า train_loss เล็กน้อย แสดงให้เห็นว่าโมเดลไม่ได้จำจำข้อมูลฝึกมากเกินไป แต่มีแนวโน้ม generalize ได้ดีต่อชุด validation ความแตกต่างระหว่าง train_loss และ val_loss ไม่กว้างมากและไม่มีช่วงที่ val_loss ตีดขึ้นอย่างรุนแรง จึงไม่ปรากฏสัญญาณ overfitting ชัดเจนในกรณีนี้




รูปที่ 3.5 กราฟ accuracy ของโมเดล Xception (Frozen base) – train_acc (สีน้ำเงิน) และ val_acc (สีส้ม) เพิ่มขึ้นอย่างรวดเร็วในช่วง 10–15 epochs แรก จากประมาณ 0.48 ขึ้นไปใกล้ 0.8 และค่อยๆ ได้ขึ้นจนแตะระดับประมาณ 0.90 ภายในช่วงกลางของการฝึก หลังจากนั้นค่า val_acc ทรงตัวใกล้ 0.90 ตลอดช่วงท้าย ในขณะที่ train_acc แก่กว่าอยู่รอบๆ 0.88–0.93 แสดงให้เห็นว่าโมเดล Xception สามารถเรียนรู้ได้และมีเสถียรภาพสูง train_acc ไม่หนีห่างจาก val_acc มากนัก จึงไม่เป็นชี้สิ่งปัญหา overfitting รุนแรง

ในแฟลชคุณภาพ เราได้พิจารณา Confusion Matrix ของ Xception บนชุด validation ดังแสดงในรูปที่ 3.6 โดยในกรณี Frozen base ไม่เดลสามารถจำแนกใบ holy_basil ได้ถูกต้องทุกภาพ (22 จาก 22 ภาพ) เช่นเดียวกับกรณีของ MobileNetV2 ในขณะที่ใบ Thai_basil ถูกจำแนกถูกต้อง 14 ภาพ จากทั้งหมด 18 ภาพ และถูกทำนายผิดว่าเป็น holy_basil จำนวน 4 ภาพ จะเห็นว่าลักษณะความผิดพลาดคล้ายกับ MobileNetV2 คือโมเดลไม่ค่อยสับสนใบกะเพราไปเป็นโลหะฯ แต่มีแนวโน้มจะมองใบโลหะบางรูปที่ลักษณะคล้ายกะเพรา (เช่น ใบไม้เม็นหรือเมื่อยหยากมาก) และทำนายผิดว่าเป็น holy_basil แทน




รูปที่ 3.6 Confusion Matrix ของโมเดล Xception บนชุด validation (Frozen base) – แสดงจำนวนภาพ Thai_basil ที่ถูกต้อง 14 และผิด 4 ภาพ ในขณะที่ holy_basil ถูกต้องทั้งหมด 22 ภาพ รวม accuracy โดยรวมประมาณ 90%

สำหรับกรณี fine-tuning โมเดล Xception เรายังได้ปลดล็อกบางชั้นของ convolutional base และฝึกต่ออีก 4 epochs โดยใช้ learning rate ที่ต่ำลงมาก ผลลัพธ์ของ loss และ accuracy แสดงในรูปที่ 3.7 และ 3.8 ตามลำดับ จะเห็นว่า val_loss ลดลงเล็กน้อยจากประมาณ 0.24 ลงมาบริเวณ ~ 0.23 ในขณะที่ train_loss ยังคงอยู่ในช่วง 0.42–0.46 ส่วน val_acc ทรงตัวใกล้ 0.90 ตลอด 4 epochs และมีการแกว่งเล็กน้อยในระดับ ± 0.02 เท่านั้น นั่นคือ การ fine-tune Xception ไม่ได้ช่วยเพิ่มความแม่นยำอย่างมีนัยสำคัญ แต่ช่วยปรับปรุงค่าความซ้ำซ้อนเสียให้ลดลงเล็กน้อย และแสดงว่าฐานโมเดลเดิมที่ฝึกจาก ImageNet นั้นเหมาะสมกับงานพอสต์ฟอร์มอยู่แล้ว และการปรับจูนเพิ่มเติมด้วยข้อมูลจำนวนน้อยจึงให้ผลต่างเพียงเล็กน้อย




รูปที่ 3.7 กราฟ loss ของโมเดล Xception กรณี fine-tuning (ฝึกต่อ 4 epochs) – train_loss มีค่าอยู่ในช่วง ~0.42–0.46 ขณะที่ val_loss ค่อยๆ ลดลงจากประมาณ 0.24 ไปใกล้ 0.22 แสดงว่าความแม่นใจของโมเดลบนชุด validation ดีขึ้นเล็กน้อย แม้ accuracy จะแทบไม่เปลี่ยน




รูปที่ 3.8 กราฟ accuracy ของโมเดล Xception กรณี fine-tuning – train_acc แก้วงอยู่ระหว่าง 0.81–0.86 ในขณะที่ val_acc เริ่มต้นที่ 0.90 และลดลงเล็กน้อยมาอยู่บริเวณ 0.88–0.89 ทำให้ได้ความแม่นยำ fine-tune ไม่ได้ช่วยเพิ่ม accuracy แต่ยังคงรักษาระดับเดิมไว้ได้

Confusion Matrix ของ Xception หลังการ fine-tune (รูปที่ 3.9) แสดงให้เห็นว่าจำนวนภาพที่จำแนกถูก/ผิดในแต่ละคลาส เมื่อเปรียบเทียบกับกรณี frozen model คือ Thai_basil ถูกต้อง 14 ผิด 4 และ holy_basil ถูกต้องทั้งหมด 22 ภาพ แสดงว่าแม้ค่า loss จะดีขึ้นเล็กน้อย แต่การ fine-tune ไม่ได้เปลี่ยนรูปแบบข้อผิดพลาดของโมเดลเลย กล่าวอีกนัยหนึ่ง โมเดล Xception ในงานนี้อยู่ในจุดที่ “เรียนรู้มากพอ” ตั้งแต่ไฟล์แรกแล้ว และการปรับอุณหต่อด้วยข้อมูลชุดเดิมเพียง 4 epochs ไม่ได้สร้าง decision boundary ใหม่ที่แตกต่างอย่างมีนัยสำคัญ




รูปที่ 3.9 Confusion matrix ของโมเดล Xception บนชุด validation หลังการ fine-tune (ปรากฏรูปแบบตัวเลข เหมือนกับ frozen ทุกประการ)


การวิเคราะห์เชิงลึกของโมเดล EfficientNetB0 ไม่แสดง EfficientNetB0 แสดงประสิทธิภาพสูงสุดในงานนี้ ทั้งในเฟส frozen base และ fine-tuning




จากกราฟ loss และ accuracy ของเฟส frozen base จะเห็นว่าค่า train_loss ลดลงเร็วและอยู่ในระดับต่ำมาก ($\sim 0.07 - 0.12$) ในขณะที่ val_loss ค่อยๆ ลดลงอย่างสม่ำเสมอจาก値 0.55 ลงมาอยู่บริเวณ ~ 0.18 ช่วงท้าย โดยไม่มีการติดขึ้นซึ่งเป็นสัญญาณ overfitting และง่ายกว่าโมเดลสามารถ generalize ได้ดี ความแม่นยำ val_acc เพิ่มขึ้นอย่างรวดเร็วแตะระดับ ~ 0.90 ภายใน ~ 10 epochs และทรงตัวอยู่ใกล้ระดับนั้นตลอดการฝึก



ในส่วน fine-tuning ค่า val_loss ยังคงลดต่อเนื่องจาก ~0.18 ลงไปใกล้ ~0.10 และ val_acc กระโดดจาก ~0.95 ในเฟส ก่อนหน้าไปแตะ 1.00 ในช่วงท้ายของการ fine-tuning ขณะที่ train_loss แกว่งอยู่ในช่วง ~0.20–0.27 ซึ่งยังถือว่าต่ำและไม่แสดงสัญญาณ overfitting ชูโรง ผลนี้ชี้ให้เห็นว่า EfficientNetB0 ตอบสนองต่อการ fine-tuning ได้ดีกว่าไม่เดลอื่นในงานนี้ และได้ประโยชน์จากการ unfreeze ชั้นบน ๆ ของ backbone อย่างสมดุล




สำหรับ confusion matrix ของ EfficientNetB0 ก่อนการ fine-tune ไม่เดลจำแนก Thai_basil ถูกต้อง 15 จาก 18 ภาพ และจำแนก holy_basil ถูกต้องทั้งหมด 22 ภาพ




หลังการ fine-tune โมเดลสามารถจำแนกภาพได้ถูกต้อง ทุกราพ (18/18 และ 22/22) ซึ่งสอดคล้องกับ val_acc = 1.00 ในไฟล์ fine-tuning แสดงให้เห็นว่า decision boundary ของโมเดลถูกปรับให้เหมาะสมกับข้อมูลมากขึ้น และไม่พบรากурсทำนายผิดของคลาสใดเลย

โดยสรุป EfficientNetB0 ไม่เพียงให้ความแม่นยำสูงที่สุด แต่ยังมีเสถียรภาพทั้งระหว่าง train/validation และยังได้ประโยชน์ชัดเจน จากการ fine-tune ซึ่งต่างจาก Xception หรือ MobileNetV2 ที่ไม่ได้ขึ้นหลังบัวบาน ทำให้ EfficientNetB0 เป็นโมเดลที่เหมาะสมที่สุดสำหรับงานจำแนกใบกระเพรา-ใบระพานในชุดข้อมูลนี้


การวิเคราะห์เชิงลึกของโมเดล ResNet50V2 ResNet50V2 เป็นโมเดลที่ใช้ skip connections ช่วยทำให้การไหลของ gradient มีเสถียรภาพมากขึ้นและป้องกันปัญหา vanishing gradient ในโมเดลลึก




จากกราฟ loss ของไฟล์ frozen base จะเห็นว่า train_loss ลดลงต่อเนื่องจนอยู่ระดับต่ำมาก ($\sim 0.07\text{--}0.12$) และมีความนิ่งในช่วงท้าย ในขณะที่ val_loss ไม่ลดลงมากเท่าโมเดล EfficientNetB0 แต่ยังคงอยู่ในช่วง $\sim 0.35\text{--}0.45$ ซึ่งสูงกว่า train_loss ค่อนข้างชัดเจนและมีการแก่งตัวพอสมควร สะท้อนว่า ResNet50V2 อาจเริ่มเรียนรู้รายละเอียดบิบอยของข้อมูลฝึกมากขึ้น และมีแนวโน้ม overfitting เล็กน้อยเมื่อเทียบกับ EfficientNetB0 หรือ Xception ในไฟล์เดียวกัน




กราฟ accuracy แสดงให้เห็นว่า train_acc เพิ่มขึ้นเรื่อยๆ จนเกือบแตะ 1.0 ในขณะที่ val_acc อยู่ประมาณ 0.92 แบบคงที่ตลอด 100 epochs โดยแทบไม่ขยับขึ้นหรือลง แสดงว่าโมเดลมีประสิทธิภาพดีและทรงตัว แต่ไม่ได้ปรับปรุงประสิทธิภาพเพิ่มขึ้นแม้ฝึกนานขึ้น ซึ่งบ่งบอกว่าการแข็ง backbone ของ ResNet50V2 อาจจำกัดความสามารถในการเรียนรู้ feature ที่จำเพาะกับใบกระเพรา-โหระพา แม้ว่าโมเดลจะ generalize ได้ระดับหนึ่งก็ตาม



สำหรับ confusion matrix ของ ResNet50V2 โมเดลจำแนก Thai_basil ถูกต้อง 16 จาก 18 ภาพ ผิด 2 ภาพ และจำแนก holy_basil ถูกต้อง 21 จาก 22 ภาพ ผิด 1 ภาพ ด้วย accuracy รวม ~92.5% ซึ่งอยู่ระหว่าง MobileNetV2 และ NASNetMobile และใกล้เคียง Xception แต่ ResNet50V2 มีความสม่ำเสมอในคลาสทั้งสองมากกว่า ไม่ได้มีคลาสใดที่ผิดมากเป็นพิเศษ




ในส่วน fine-tuning การ unfreeze ประมาณ 20% สุดท้ายของชั้น ResNet50V2 และฝึกต่ออีก 4 epochs ทำให้ train_loss ลดลงมากจากเดิม แต่ val_loss กลับนิ่งอยู่ระดับ $\sim 0.39\text{--}0.40$ โดยไม่ปรับปูน ขณะที่ val_acc ยังคงอยู่ระดับ ~ 0.925 เมื่อคุณเดิมแสดงว่า การ fine-tuning ไม่ได้ช่วยเพิ่มประสิทธิภาพของ ResNet50V2 เลย ตรงกันข้าม train_acc ขึ้นสูงมากถึง ~ 0.98 ก่อนจะตกกลับมา ~ 0.93 ทำให้เห็นสัญญาณ overfitting ชัดเจนเมื่อ weight ถูกปรับมากเกินไปจากข้อมูลน้อย




Confusion Matrix หลัง fine-tuning ยืนยันแนวโน้มเดียวกัน โดยจำนวนภาพที่จำแนกถูกผิดของทั้งสองคลาสเหมือนเดิมทุกประการ กับผล frozen base คือ Thai_basil 16/18 และ holy_basil 21/22 แสดงว่า fine-tuning ไม่ได้สร้าง decision boundary ใหม่ที่แตกต่างจากเดิมเลย และ ResNet50V2 มีแนวโน้มเรียนรู้เพียงพอตั้งแต่เฟสแรกแล้ว

โดยสรุป ResNet50V2 เป็นโมเดลที่ให้ผลลัพธ์นี้ดีและเสถียร แต่ไม่ดีเท่า EfficientNetB0 เนื่องจากไม่สามารถลด val_loss ลงได้มาก และไม่ตอบสนองต่อ fine-tuning เท่าที่ควร แม้จะมีศักยภาพของโมเดลลึก แต่ dataset ที่มีขนาดจำกัดทำให้ความสามารถระดับสูงของ ResNet50V2 ไม่ได้ถูกใช้เต็มประสิทธิภาพ


การวิเคราะห์เชิงลึกของโมเดล NASNetMobile NASNetMobile เป็นสถาปัตยกรรมที่ถูกออกแบบด้วย neural architecture search ทำให้มีโครงสร้างที่ค่อนข้างซับซ้อนเมื่อเทียบกับโมเดลระดับ mobile ทั่วไป อย่างไรก็ตาม จากผลการทดลองในงานนี้ พบว่า NASNetMobile ทำงานได้ดีระดับกลางค่อนไปทางดี แต่ไม่โดดเด่นเท่า EfficientNetB0 หรือ ResNet50V2




จากกราฟ loss ในเฟส frozen base train_loss ลดลงสม่ำเสมอและค่อนข้างต่ำ ($\sim 0.12\text{--}0.20$) และ val_loss คงตัวอยู่ช่วง ~0.28–0.35 โดยแทบไม่ลดลงในช่วงหลังของการฝึก ซึ่งสะท้อนว่าโมเดลเรียนรู้ pattern ของ training set ได้ดี แต่ไม่สามารถ generalize เพิ่มขึ้นเมื่อ epoch สูงขึ้น สัญญาณนี้ชี้ว่า mild overfitting ตั้งแต่ช่วงกตางการฝึกโดยเฉพาะจาก epoch 40 เป็นต้นไป




กราฟ accuracy train_acc แสดงระดับ ~0.95–0.97 ในช่วงท้าย ในขณะที่ val_acc อยู่ประมาณ ~0.88–0.90 แบบทรงตัวไม่เพิ่มขึ้นต่อหลังช่วง ~epoch 25–30 และงว่าโมเดลเรียนรู้ feature สำคัญได้ระดับหนึ่งแต่ dataset มีความซับซ้อนไม่พอให้โมเดลซับซ้อนอย่าง NASNetMobile ได้แสดงประสิทธิภาพเต็มที่



จาก confusion matrix แบบ frozen โมเดลจำแนก Thai_basil ได้ถูกต้อง 16/18 และ holy_basil ถูก 19/22 ซึ่งเป็นอัตราที่รองจาก EfficientNetB0 และ ResNet50V2 แต่ยังคงอยู่ในระดับที่ใช้งานได้ดี




ในไฟล์ fine-tuning (อุปที่ — กราฟ loss FT NASNetMobile และวูปที่ — กราฟ accuracy FT NASNetMobile) ผลลัพธ์ชัดเจนว่า fine-tuning ไม่ได้ช่วยเพิ่มประสิทธิภาพของโมเดลเลย ค่า val_loss ผู้จี้นเล็กน้อย ($\sim 0.31 \rightarrow \sim 0.34$) และ val_acc ลดลงจาก ~ 0.90 เหลือ $\sim 0.85\text{--}0.87$ ตลอด 4 epochs ซึ่งเป็นสัญญาณตรงว่าการ unfreeze ชั้นบนของ NASNetMobile ทำให้โมเดลปรับตัวเข้าหา noise มากกว่าข้อมูลจริง



Confusion Matrix หลัง fine-tune (ชุดที่ — CM FT NASNetMobile) ให้ผลแม่นี่อนเดิมทุกประการกับไฟส frozen base (Thai_basil 16/18 และ holy_basil 19/22) ซึ่งสะท้อนว่า decision boundary ของ NASNetMobile ไม่ได้ถูกปรับในทางที่ดีขึ้นเลย

โดยสรุป NASNetMobile ให้ผลลัพธ์ดีระดับหนึ่ง แต่มีข้อจำกัดชัดเจนเมื่อเทียบกับ EfficientNetB0 และ Xception โดยเฉพาะด้าน generalization และการตอบสนองต่อ fine-tuning ทำให้เหมาะสมกับงานที่ความซับซ้อนต่ำกว่า หรือ dataset มีขนาดใหญ่กว่า นี้เพื่อให้ไม่เดลซับซ้อนระดับ NASNet ดึงศักยภาพออกมากได้เต็มที่

สรุปภาพรวมเพิ่มเติมจากการฟีรี่บเทียบ (Validation Accuracy & Loss Curves)




จากกราฟรวม (Val Accuracy และ Val Loss) ของโมเดลทั้ง 5 ตัว จะเห็นภาพรวมดังนี้:

EfficientNetB0 เด่นที่สุด ทั้งด้านความแม่นยำและความเสถียรของ loss โดยกราฟ val_loss ลดลงสม่ำเสมอที่สุด และไม่เกิดการดีดขึ้นท้าย epochs

ResNet50V2 และ NASNetMobile ให้ผลระดับกลางค่อนไปทางสูง แต่กราฟ loss แกว่งตัวมาก แสดงสัญญาณ overfitting เล็กน้อย

MobileNetV2 มี val_acc ตื่นช่วงแรก แต่ val_loss แกว่งตัวสูงที่สุดในกลุ่ม สะท้อนความไวต่อ noise และข้อจำกัดของโมเดลขนาดเล็ก

Xception แม้ accuracy ต่ำสุดในกลุ่ม frozen แต่ loss ลดลงนิ่งและเสถียร ถือเป็นโมเดลที่ generalize ได้ดีในระดับข้อมูลจำกัด



กราฟแท่งสรุป (Pretrained Model Comparison) แสดงให้เห็นชัดว่า EfficientNetB0 มี val_accuracy สูงที่สุด (1.00 หลัง fine-tuning) ซึ่งสอดคล้องกับพฤติกรรมจากการฟีรี่บเทียบ

3.3 ตัวอย่างภาพของข้อมูลที่ใช้ในการทดลอง

เพื่อความชัดเจน ในรูปที่ 3.4–3.6 แสดงตัวอย่างภาพในแต่ละประเภทของข้อมูลที่ใช้ในโครงการนี้ ได้แก่
ตัวอย่างภาพผลกล้วยและภาพใบกะเพรา/โหระพา



รูปที่ 3.4 ตัวอย่างภาพกล้วยหอม (หนึ่งในสามสายพันธุ์กล้วยที่ใช้ในการทดลอง) – กล้วยหอมมีลักษณะผลยาวโถ้งผิวเปลือกสีเหลืองมีจุดสีน้ำตาลประปราย เมื่อเปรียบเทียบกับกล้วยน้ำว้าหรือกล้วยไข่จะเห็นว่ากล้วยหอมมีขนาดใหญ่และเรียวยาวกว่าทำให้เป็นจุดแตกต่างสำคัญที่โมเดลสามารถใช้แยกสายพันธุ์ได้



รูปที่ 3.5 ตัวอย่างภาพใบกะเพรา (Holy basil) – ใบกะเพรา มีสีเขียวอ่อนด้าน ผิวใบสากเล็กน้อย
ขอบใบหยักแบบพันเลือยไม่เป็นระเบียบ และมักไม่มีดอกให้เห็นชัดในภาพ ใบค่อนข้างบางและเส้นใบชัดเจน
ก้านใบและก้านช่อดอกมีสีเขียวอ่อน การแยกใบกะเพราออกจากใบโหระพาด้วยดาเปล่าทำได้โดยสังเกตขอบใบและผิวใบที่สากกว่า



รูปที่ 3.6 ตัวอย่างภาพใบโภระพา (Thai sweet basil) – ใบโภระพา มีลักษณะเป็นรูปร่องใบเรียกว่า ปลายใบแหลม ขอบใบค่อนข้างเรียบหรือหยักน้อยกว่าจะเปรรา ผิวใบเรียบมันมากกว่า ใบหนากว่าเล็กน้อย
นอกจากนี้ลักษณะเด่นคือมักมีส่วนของลำต้นหรือซอดอกสีม่วงให้เห็น (ดังในภาพจะเห็นก้านและยอดดอกสีม่วงแดง)
กลิ่นของใบโภระพาหอมกว่าแต่ในภาพถ่ายต้องอาศัยลักษณะทางสายตาดังที่กล่าวมาในการจำแนก

จากตัวอย่างภาพข้างต้น โมเดล Machine Learning และ CNN ในงานนี้จะได้รับข้อมูลที่มีลักษณะดังที่เห็น
ซึ่งโมเดลจำเป็นต้องเรียนรู้ความแตกต่างเพียงเล็กน้อยของรูปร่างและรายละเอียดพื้นผิว/เส้นใบเพื่อนำไปสู่การจำแนกที่ถูกต้อง

บทที่ 4 อภิปรายผล

จากการทดลองในบทที่ 3 สามารถสรุปและอภิปรายประเด็นที่นำเสนอเกี่ยวกับประสิทธิภาพของโมเดลต่าง ๆ และลักษณะของข้อมูลได้ดังนี้:

4.1 เปรียบเทียบโมเดลที่ดีที่สุดในแต่ละกรณี

การจำแนกสายพันธุ์กล้วยด้วยวิธี Machine Learning พบร่วมกัน Logistic Regression และเป็นโมเดลเชิงเส้น แต่สามารถใช้ประโยชน์จากชุดฟีเจอร์ที่สกัดมาได้ดี (shape, LBP, HOG) จึงแยกสายพันธุ์ได้แม่นยำ ขณะที่ Random Forest และ MLP ก็ให้ผลดีของลงมา ส่วน Decision Tree มีแนวโน้มจำข้อมูลมากเกินไป (overfit) และ Naïve Bayes ไม่เหมาะสมกับฟีเจอร์ที่มีความสัมพันธ์กันสูง

สำหรับงานจำแนกใบกะเพรา–ไข่หวานด้วย CNN โมเดลที่ดีที่สุดคือ EfficientNetB0 ซึ่งใช้จำนวนพารามิเตอร์น้อยแต่ให้ความแม่นยำสูง หมายเหตุบางงานที่ข้อมูลมีจำนวนจำกัด โมเดลที่ขับข้อนกว่านี้ เช่น ResNet50V2 หรือ NASNetMobile แม้จะดีกว่าชุดนี้ แต่ไม่ได้ให้ผลเพิ่มขึ้นภายใต้ขนาดข้อมูลชุดนี้

4.2 ปัญหา Overfitting ที่พบ

โมเดลบางตัว โดยเฉพาะ CNN ในช่วง fine-tuning แสดงอาการ overfitting ชัดเจน เช่น ความแม่นยำบนชุดฝึกเพิ่มขึ้น แต่ความแม่นยำบนชุด validation ลดลง สาเหตุหลักมาจากการจำแนกข้อมูลที่น้อยและความขับข้อนของโมเดลที่สูง การใช้ data augmentation ช่วยลดผลกระทบได้บ้าง แต่ยังไม่เพียงพอในบางกรณี

ในฝั่ง Machine Learning เช่น Decision Tree ก็พบอาการลักษณะเดียวกัน โดย train accuracy ถูกลากแต่ validation accuracy ต่ำกว่าอย่างเห็นได้ชัด ทำให้ Random Forest ซึ่งรวมตัวไว้หลายต้นกล้าอยู่เป็นทางเลือกที่เสถียรและทนต่อ overfitting มากกว่า

4.3 การวิเคราะห์จาก Confusion Matrix

งานใบกะเพรา–ไข่หวาน (CNN)

โมเดลเกือบทุกด้วยแบบไม่สับสน *holy_basil* → *Thai_basil* แต่มีโอกาสสับสน *Thai_basil* → *holy_basil* มากกว่า โดยเฉพาะภาพที่มีลักษณะคล้ายกะเพรา เช่น ใบหยกมากหรือสีคล้ำ ๆ ทำให้โมเดลถูกดึงไปทำงานเป็น *holy_basil*

งานกล้วย 3 สายพันธุ์ (Machine Learning) – จาก Confusion Matrix ที่ได้

- คุณที่สับสนมากที่สุดคือ กล้วยน้ำว้า ↔ กล้วยไข่ เพราะมีรูปทรงและพื้นผิวใกล้เคียงที่สุด
- กล้วยหอม ถูกจำแนกได้ดีที่สุด เนื่องจากมีลักษณะเด่นชัด เช่น ความโค้งและขนาดเฉพาะตัว
- Logistic Regression และ Random Forest มีจุดผิดพลาดน้อยที่สุด ขณะที่ Decision Tree ผิดยอดน้อยที่สุด เพราะ overfit

4.4 ข้อดีข้อเสียของวิธีการแต่ละแบบ

Machine Learning แบบดั้งเดิม: ข้อดีคือ ตีความง่ายและปรับแต่งได้ตรงจุด เช่น วิเคราะห์ได้ว่าไฟเจอร์ใดสำคัญ แต่ข้อเสียคือข้อมูลกับคุณภาพของไฟเจอร์ที่สกัด หากเลือกไฟเจอร์ไม่ดี โมเดลจะไม่สามารถดึงความแตกต่างที่แท้จริงออกมายได้

Deep Learning (CNN): ข้อดีคือ ไม่ต้องออกแบบไฟเจอร์เอง โมเดลเรียนรู้คุณลักษณะที่สำคัญจากภาพได้โดยตรง หมายความว่า หมายความว่า คุณภาพและความสมดุลของข้อมูลส่งผลต่อผลลัพธ์อย่างมาก โดยเฉพาะงานใบสมุนไพรที่มีตัวอย่างค่อนข้างน้อย แต่ด้วยการใช้ **data augmentation** และโครงสร้างโมเดลที่เหมาะสม ทำให้โมเดลยังคงให้ผลแม่นยำสูง จุดนี้สะท้อนว่าในวิบที่ข้อมูลจำกัด การเลือกโมเดลและการเตรียมข้อมูลมีผลต่อความสำเร็จมากกว่าแค่เลือกโมเดลที่ใหญ่ที่สุดหรือขับข้อนที่สุด

4.5 ข้อสังเกตเพิ่มเติม

คุณภาพและความสมดุลของข้อมูลส่งผลต่อผลลัพธ์อย่างมาก โดยเฉพาะงานใบสมุนไพรที่มีตัวอย่างค่อนข้างน้อย แต่ด้วยการใช้ **data augmentation** และโครงสร้างโมเดลที่เหมาะสม ทำให้โมเดลยังคงให้ผลแม่นยำสูง จุดนี้สะท้อนว่าในวิบที่ข้อมูลจำกัด การเลือกโมเดลและการเตรียมข้อมูลมีผลต่อความสำเร็จมากกว่าแค่เลือกโมเดลที่ใหญ่ที่สุดหรือขับข้อนที่สุด